#### 2024年秋季学期《编译原理和技术》



## 中间代码表示

李诚

国家高性能计算中心(合肥)、信息与计算机国家级实验教学示范中心 计算机科学与技术学院 2024年9月30日



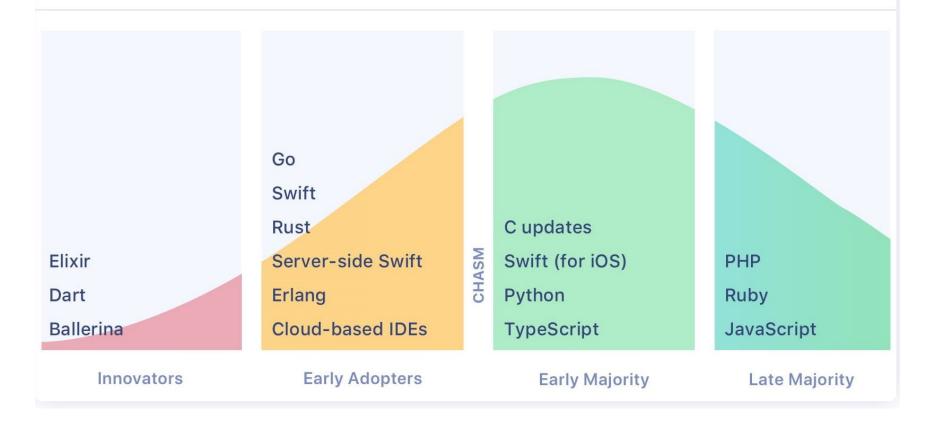
## → 为什么需要中间代码表示?



Software Development **Programming Languages Trends 2019 Q3 Graph** 

http://info.link/proglang2019







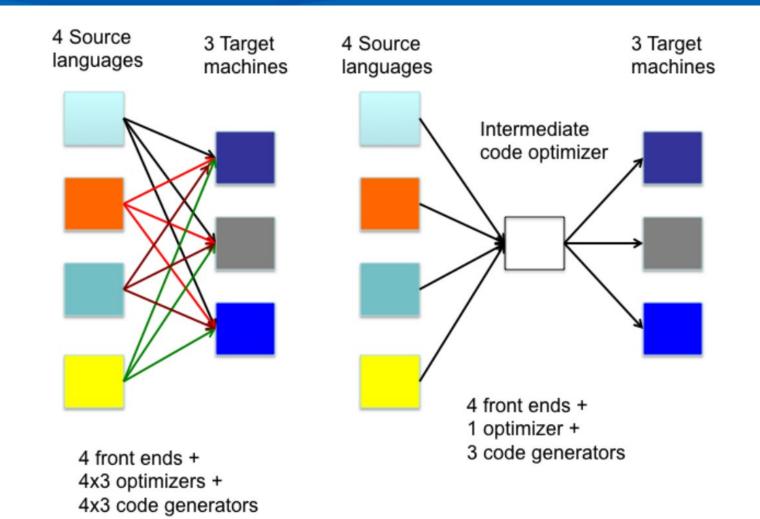
## 分 为什么需要中间代码表示?

分类	名称	版本	扩展	初始年份
CISC	x86	16, 32, 64 (16→32→64)	x87, IA-32, MMX, 3DNow!, SSE, SSE2, PAE, x86-64, SSE3, SSSE3, SSE4, BMI, AVX, AES, FMA, XOP, F16C	1978
RISC	MIPS	32	MDMX, MIPS-3D	1981
VLIW	Elbrus	64	Just-in-time dynamic trans- lation: x87, IA-32, MMX, SSE, SSE2, x86-64, SSE3, AVX	2014



## ② 为什么需要中间代码表示?



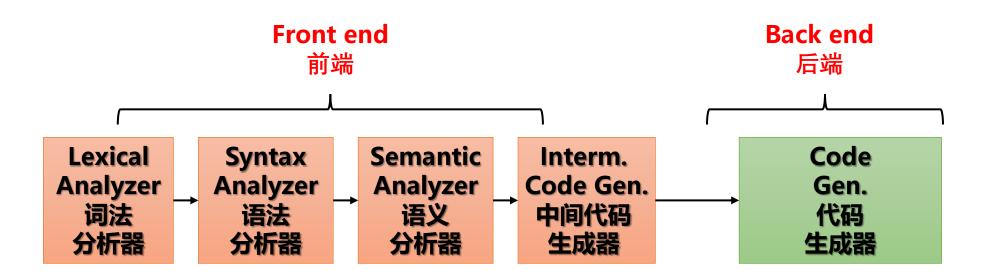


实践过程中, 推陈出新的语言、不断涌现的指令集、开发成本之间的权衡



#### 为什么需要中间代码表示





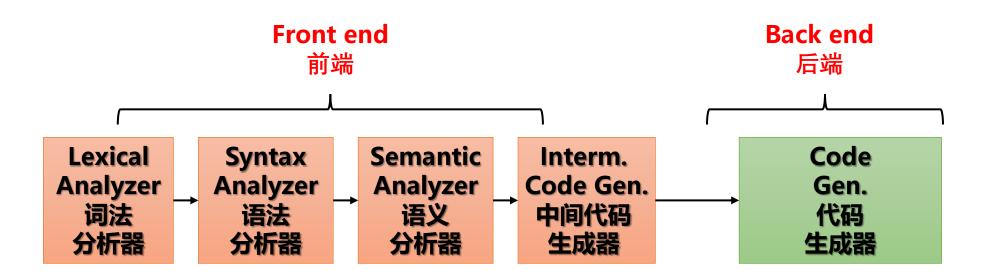
#### ・前端与后端分离

• 为新机器构建编译器, 只需要设计从中间代码到新的目标机器代码的编译器 (前端独立)



### 为什么需要中间代码表示





#### ・前端与后端分离

- 为新机器构建编译器, 只需要设计从中间代码到新的目标机器代码的编译器(前端独立)
- 中间代码优化与源语言和目标机器均无关



## 中间表示有哪些类型?



- 简而言之,编译器任何完整的中间输出都是中间代码表示形式
- ・常见类型有:
  - 后缀表示
  - 语法树或DAG图
  - 三地址码(TAC)
  - ·静态单赋值形式(SSA)

重点关注 LLVM IR是TAC类型





#### uop是一元运 算符

$$E \rightarrow E opE \mid uopE \mid (E) \mid id \mid num$$

表达式E

后缀式E′

id

num

 $E_1 op E_2$ 

*uopE* 

(E)

id

num

 $E_1' E_2' op$ 

E'uop

E'



#### 后缀表示



#### ・后缀表示不需要括号

#### · 后缀表示的最大优点是便于计算机处理表达式 计算栈 输入串

8

85

3

3 2

5

$$85 - 2 +$$

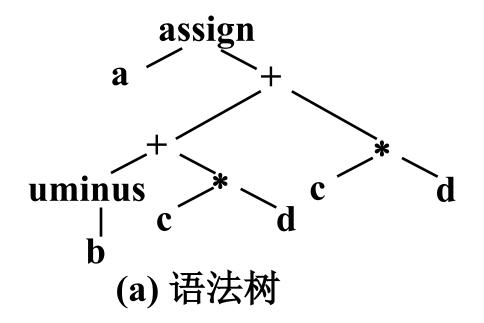
$$5 - 2 +$$

$$-2 +$$

+



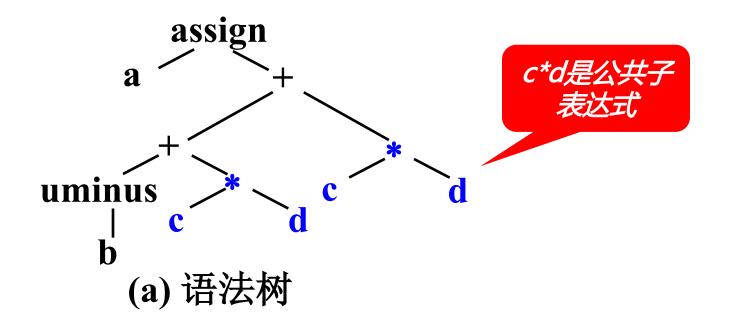
#### ·语法树是一种图形化的中间表示



$$a = (-b + c*d) + c*d$$
的图形表示



#### ·语法树是一种图形化的中间表示

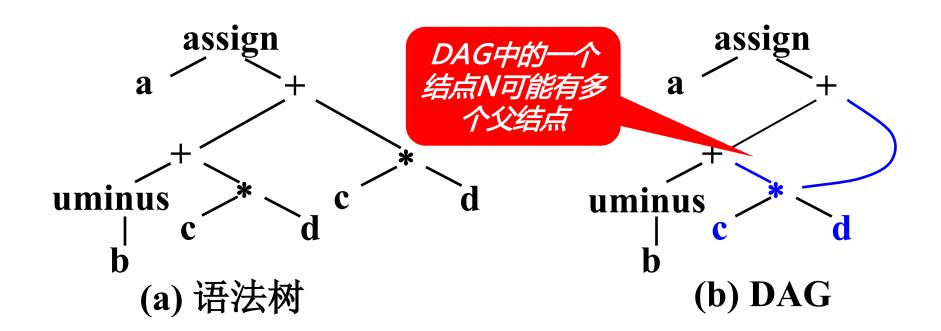


$$a = (-b + c*d) + c*d$$
的图形表示





- ・语法树是一种图形化的中间表示
- · 有向无环图(Directed Acyclic Graph, DAG)也是一种中间表示



a = (-b + c\*d) + c\*d的图形表示

### 三地址代码



• 三地址代码 (Three-Address Code, TAC)

一般形式: x = y op z

- 最多一个算符
- 最多三个计算分量
- 每一个分量代表一个 地址,因此三地址
- 例 表达式x + y \* z翻译成的三地址语句序列

$$t_1 = y * z$$

$$t_2 = x + t_1$$

## 三地址代码



#### · 三地址代码是语法树或DAG的一种线性表示

• 例 
$$a = (-b + c*d) + c*d$$

语法树的代码

$$t_1 = -b$$

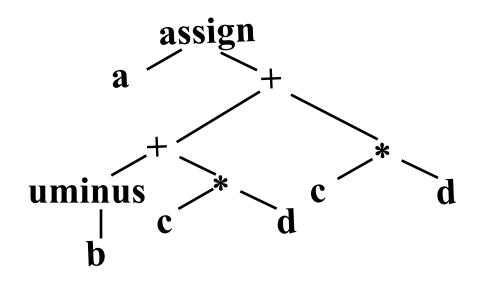
$$t_2 = c * d$$

$$t_3 = t_1 + t_2$$

$$t_4 = c * d$$

$$t_5 = t_3 + t_4$$

$$a = t_5$$



#### 三地址代码



#### · 三地址代码是语法树或DAG的一种线性表示

$$a = (-b + c*d) + c*d$$

DAG的代码

$$t_1 = -b$$

$$t_1 = -b$$

$$t_2 = c * d$$

$$t_2 = c * d$$

$$t_3 = t_1 + t_2$$

$$t_3 = t_1 + t_2$$

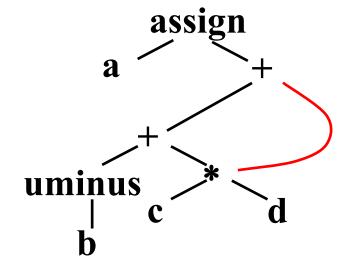
$$t_4 = c * d$$

$$t_4 = t_3 + t_2$$

$$t_5 = t_3 + t_4$$

$$a=t_4$$

$$a=t_5$$



## ② 三地址代码



#### ・常用的三地址语句

•运算/赋值语句 x = y op z, x = op y, x = y

• 无条件转移 goto L

• 条件转移1 if x goto L, if False x goto L

• 条件转移2 if x relop y goto L

## ② 三地址代码



#### ・常用的三地址语句

- 过程调用
  - param x<sub>1</sub> //设置参数
  - param  $x_2$
  - •
  - param  $x_n$
  - call p, n //调用子过程p, n为参数个数
- 过程返回 return y
- 索引赋值 x = y[i] 和 x[i] = y
  - 注意: i表示距离y处i个内存单元
- 地址和指针赋值 x = &y, x = \*y 和 \*x = y



### ② 三地址代码翻译: 举例



#### ·考虑语句,令数组a的每个元素占8存储单元

• do i = i + 1; while (a[i] < v);

```
L: t_1 = i + 1
    t_2 = i * 8
    t_3 = a[t_2]
    if t_3 < v goto L
```

符号标号

```
100: t_1 = i + 1
101: i = t_1
102: t_2 = i^* 8
103: t_3 = a[t_2]
104: if t_3 < v goto 100
```

位置标号



## 静态单赋值形式



- 一种便于某些代码优化的中间表示
- 和三地址代码的主要区别
  - 所有赋值指令都是对不同名字的变量的赋值

三地址代码 静态单赋值形式 
$$p = a + b$$
  $p_1 = a + b$   $q = p - c$   $q_1 = p_1 - c$   $p = q * d$   $p_2 = q_1 * d$   $p = e - p$   $p_3 = e - p_2$   $q = p + q$   $q_2 = p_3 + q_1$ 

SSA由Barry K. Rosen、Mark N. Wegman和 F. Kenneth Zadeck于1988年提出

## 静态单赋值形式



- 一种便于某些代码优化的中间表示
- 和三地址代码的主要区别
  - 所有赋值指令都是对不同名字的变量的赋值
  - 同一个变量在不同控制流路径上都被定值 if (flag) x = -1; else x = 1; y = x \* a;
     改成 if (flag) x<sub>1</sub> = -1; else x<sub>2</sub> = 1; x<sub>3</sub> = φ(x<sub>1</sub>, x<sub>2</sub>); //由flag的值决定用x<sub>1</sub>还是x<sub>2</sub> y = x<sub>3</sub> \* a;



# 1958 1958 Indicated of the state of the stat

#### 快速排序程序片段如下

```
i = m - 1; j = n; v = a[n];
while (1) {
  do i = i +1; while(a[i] < v);
  do j = j -1; while (a[j] > v);
  if (i >= j) break;
  x = a[i]; a[i] = a[j]; a[j] = x;
}
x = a[i]; a[i] = a[n]; a[n] = x;
```

(30) a[t15] := x

(15) x := a[t6]



· 连续的三地址指令序列,控制流从它的开始进入,并从它的末尾离 开,中间没有停止或分支的可能性(末尾除外)

## 基本块划分算法



• 输入:三地址指令序列

•输出:基本块列表

•算法:

- · 首先确定基本块的第一个指令, 即首指令(leader)
  - 指令序列的第一条三地址指令是一个首指令
  - 任意转移指令的目标指令是一个首指令
  - 紧跟一个转移指令的指令是一个首指令
- · 然后,每个首指令对应的基本块包括了从它自己开始,直到下一个首指令(不含)或指令序列结尾之间的所有指令



$$(1) i := m - 1$$

$$(2) j := n$$

$$(3) t1 := 4 * n$$

$$(4) v := a[t1]$$

$$(5) i := i + 1$$

$$(6) t2 := 4 * i$$

$$(7) t3 := a[t2]$$

(8) if 
$$t3 < v \text{ goto}$$
 (5)

(9) 
$$j := j - 1$$

$$(10) t4 := 4 * j$$

$$(11) t5 := a[t4]$$

(12) if 
$$t5 > v goto (9)$$

(13) if 
$$i >= j \text{ goto } (23)$$

$$(14)$$
 t6 := 4 \* i

$$(15) x := a[t6]$$

$$(16) t7 := 4 * i$$

$$(17)$$
 t8 := 4 \* j

$$(18) t9 := a[t8]$$

$$(19)$$
 a[t7] := t9

$$(20)$$
  $t10 := 4 * j$ 

$$(21)$$
 a[t10] := x

$$(23)$$
  $t11 := 4 * i$ 

$$(24) x := a[t11]$$

$$(25)$$
  $t12 := 4 * i$ 

$$(26)$$
  $t13 := 4 * n$ 

$$(27)$$
  $t14 := a[t13]$ 

$$(28)$$
 a[t12] := t14

$$(29)$$
  $t15 := 4 * n$ 

$$(30)$$
 a[t15] := x

#### 举例——首指令



- (1) i := m 1
- (2) j := n
- (3) t1 := 4 \* n
- (4) v := a[t1]
- (5) i := i + 1
- (6) t2 := 4 \* i
- (7) t3 := a[t2]
- (8) if t3 < v goto (5)
- (9) j := j 1
- (10) t4 := 4 \* j
- (11) t5 := a[t4]
- (12) if t5 > v goto (9)
- (13) if i >= j goto (23)
- (14) t6 := 4 \* i
- (15) x := a[t6]

- (16) t7 := 4 \* i
- (17) t8 := 4 \* j
- (18) t9 := a[t8]
- (19) a[t7] := t9
- (20) t10 := 4 \* j
- (21) a[t10] := x
- (22) goto (5)
- (23) t11 := 4 \* i
- (24) x := a[t11]
- (25) t12 := 4 \* i
- (26) t13 := 4 \* n
- (27) t14 := a[t13]
- (28) a[t12] := t14
- (29) t15 := 4 \* n
- (30) a[t15] := x

#### 举例——基本块



```
(1) i := m - 1
                                            (16) t7 := 4 * i
       (2) j := n
                                            (17) t8 := 4 * j
B_1
       (3) t1 := 4 * n
                                            (18) t9 := a[t8]
       (4) v := a[t1]
                                            (19) a[t7] := t9
      (5) i := i + 1
                                            (20) t10 := 4 * j
       (6) t2 := 4 * i
                                            (21) a[t10] := x
B_2
       (7) t3 := a[t2]
                                            (22) goto (5)
       (8) if t3 < v \text{ goto} (5)
                                            (23) t11 := 4 * i
       (9) j := j - 1
                                            (24) x := a[t11]
       (10) t4 := 4 * j
                                            (25) t12 := 4 * i
B_3
       (11) t5 := a[t4]
                                            (26) t13 := 4 * n
       (12) if t5 > v goto (9)
                                            (27) t14 := a[t13]
B_4 (13) if i >= j goto (23)
                                            (28) a[t12] := t14
       (14) t6 := 4 * i
                                            (29) t15 := 4 * n
       (15) x := a[t6]
                                            (30) a[t15] := x
```



## 流图 (Flow graph)



- ・流图的结点是一些基本块
- ·从基本块B到基本块C之间有一条边,当且仅当C的第一个指令可能 紧跟在B的最后一条指令之后执行
  - B是C的前驱 (predecessor)
  - C是B的后继(successor)



## 流图 (Flow graph)



- ・流图的结点是一些基本块
- ·从基本块B到基本块C之间有一条边,当且仅当C的第一个指令可能 紧跟在B的最后一条指令之后执行,判定方法如下:
  - 有一个从B的结尾跳转到C的开头的跳转指令
  - · 参考原来三地址指令序列中的顺序, C紧跟在B之后,且B的结尾没有 无条件跳转指令

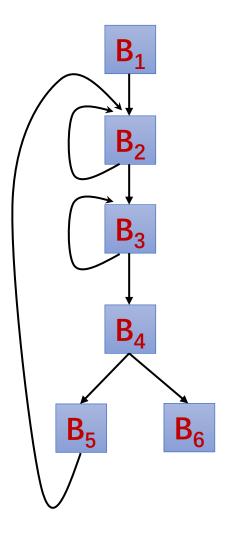
### 举例——流图



```
(1) i := m - 1
\mathbf{B_1} (2) j := n
    (3) t1 := 4 * n
  (4) v := a[t1]
    (5) i := i + 1
\mathbf{B}_{2} (6) t2 := 4 * i
    (7) t3 := a[t2]
   (8) if t3 < v \text{ goto } (5)
   (9) j := j - 1
    (10) t4 := 4 * j
B_3 (11) t5 := a[t4]
    (12) if t5 > v goto (9)
B_4 (13) if i >= j goto (23)
    (14) t6 := 4 * i
    (15) x := a[t6]
```

(29) t15 := 4 \* n

(30) a[t15] := x

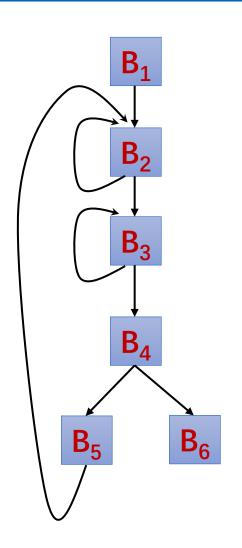






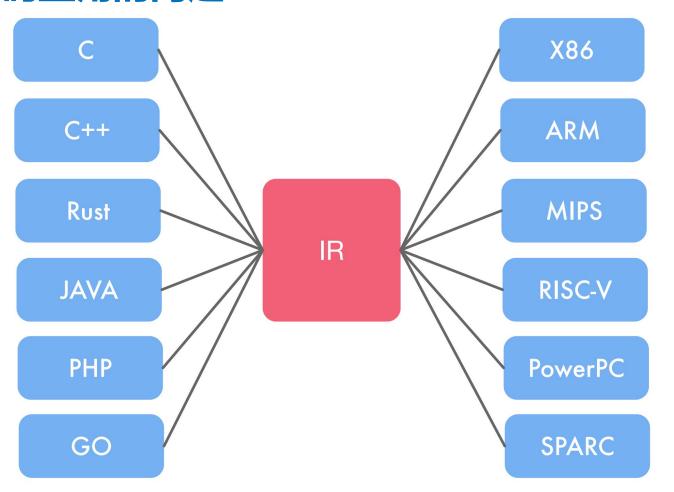
## ·流图中的一个结点集合L是一个循环,如果它满足:

- 该集合有唯一的入口结点
- 任意结点都有一个到达入口结点的非空路径, 且该路径全部在L中
- 不包含其他循环的循环叫做内循环
- ·右图中的循环
  - B<sub>2</sub>自身
  - B<sub>3</sub>自身
  - $\{B_2, B_3, B_4, B_5\}$



## LLVM 出现

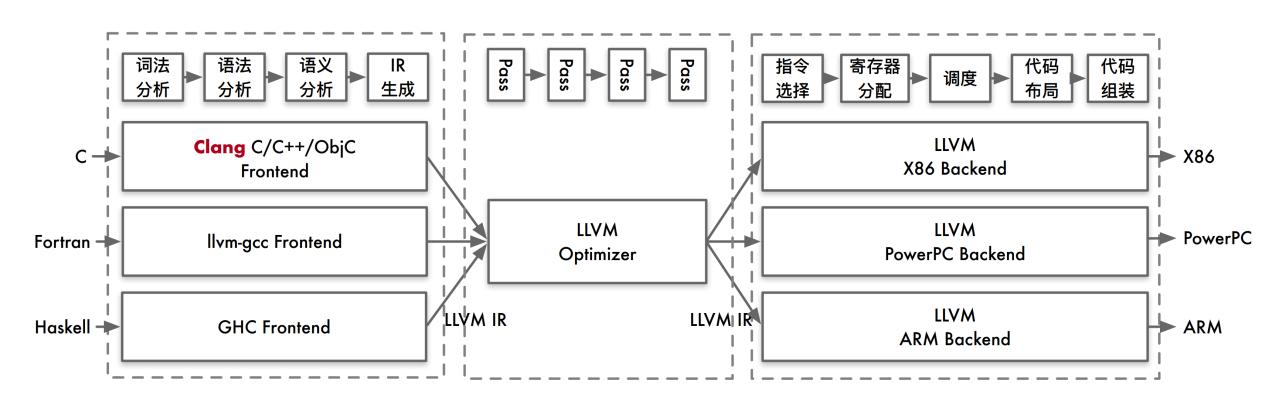
## □LLVM 定义了LLVM IR,将编译器需要的功能包装成库,解决了编译器代码重用的问题





### LLVM 架构

## □LLVM 将很多编译器需要的功能包装成库,供其他编译器实现者根据需要使用或者扩展



### LLVM 在工业界的广泛使用



## □工业界使用者(包括 Apple, Huawei, Intel, NVIDIA, Adobe, Sony... 30+ 公司使用 LLVM 开发相应产品)

Company	Description		
Apple	iOS, macOS, tvOS and watchOS		
Huawei	BiSheng Compiler for Huawei's Kunpeng servers		
Intel	OpenCL* compiler, debugger		
NVIDIA	OpenCL runtime compiler (Clang + LLVM)		









#### LLVM 在学术界的广泛使用

□学术界使用者(包括 CMU, ETH, UIUC, UCLA, Stanford ... 在内 20+ 顶尖大学研究组使用 LLVM 完成相关研究项目)

Organization	People	Description
CMU	David Koes	Principled Compilation
Stanford	Dawson Engler's Research Group	KLEE Symbolic Virtual Machine
ETH Zurich	Thomas Lenherr	Language-independent library for alias analysis
UCLA	Jason Cong	xPilot behavioral synthesis system

□教育界使用者(包括 CMU, ETH, UIUC, UCLA ... 在内10+已公开的顶 尖大学编译课程中使用 LLVM 工具链设计实验)

## LLVM IR与 LightIR



#### □LLVM IR 特点

- ■LLVM IR 采用 RISC 风格的三地址指令方式, 形如 %2 = add i32 %0, %1
- ■LLVM IR 是 SSA 形式, 且具有无限虚拟寄存器的假设
  - ▶注: SSA形式指的是静态单赋值形式,每个虚拟寄存器变量只会被赋值一次
- ■LLVM IR 是强类型系统,每个指令及操作数都具有自身的类型

## □LLVM IR 的目标是成为一种通用 IR (支持包括动态与静态语言), 因此 IR 指令种类较为复杂繁多

■本课程以 cminusf 语言为源语言,从 LLVM IR 中裁剪出了适用于教学的精简的IR 子集,并将其命名为 LightIR

## LLVM IR 库与 LightIR 库



#### □LLVM 提供了辅助生成 IR 的C++库

- ■LLVM IR 库用于课程实验的问题
  - ▶类继承关系过于复杂,不利于学生理解 IR 抽象
  - ▶ 存在很多为了编译性能的额外设计,不利于学生理解 IR 抽象

#### □本课程依据 LLVM 的设计,为 LightIR 提供了配套简化的 C++ 库

- LightIR C++库与 LLVM IR C++库的联系
  - > 仅保留必要的核心类, 简化了核心类的继承关系与成员设计
  - > 给学生提供与 LLVM 相同的生成 IR 的接口

#### □下面将对LightIR的结构层次与具体指令进行详细介绍



#### □结构层次

■ Module:是Light IR中最顶层的结构,每个Cminus-f程序对应了一个Module,在 Module中存在GlobalVariable域与Function域

Module



#### □结构层次

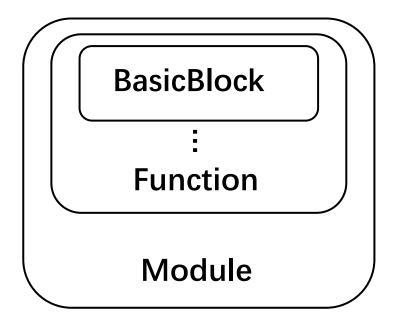
- Module
- ■Function: 是函数,由头部与函数体组成。函数头部包括返回值类型,函数名,与参数表。函数体由多个BasicBlock构成,一个module中至少需要包含一个main函数

Function Module



#### □结构层次

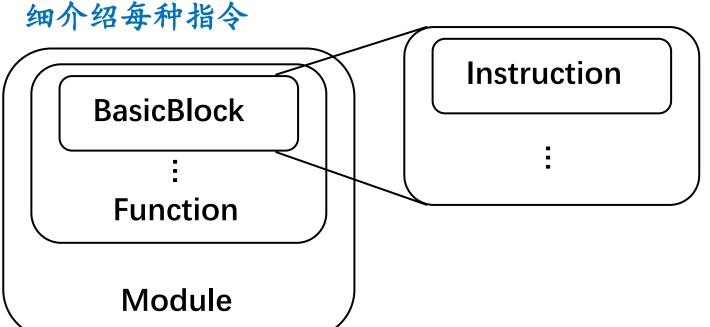
- **■** Module
- **■** Function
- ■BasicBlock: 是指程序顺序执行的语句序列,只有一个入口和一个出口。基本块由若干Instruction构成





#### □结构层次

- **■** Module
- **■** Function
- **■** BasicBlock
- ■Instruction:包含了Light IR从LLVM IR中裁剪出来的所有指令种类,接下来将详如众如东和北公



### LightIR 片段



```
@y = global i32 36
define i32 @main() #0 {
 %1 = alloca i32
 %2 = alloca i32
 store i32 0, i32* %1
 store i32 16, i32* %2
 %3 = load i32, i32* %2
 %4 = load i32, i32* @y
 %5 = icmp sgt i32 %3, %4
 br i1 %5, label %6, label %10
                                                         → Module
                                 ; preds = \%0
6:
 %7 = load i32, i32* %2
 %8 = load i32, i32* @y
 %9 = sub nsw i32 %7, %8
 store i32 %9, i32* %2
 br label %10
10:
                                 ; preds = \%6, \%0
 %11 = load i32, i32* %1
 ret i32 %11
```

### LightIR 片段

1958 1958 and Technologic

@y = global i32 36

GlobalVariable

```
define i32 @main() #0 {
 %1 = alloca i32
 %2 = alloca i32
 store i32 0, i32* %1
 store i32 16, i32* %2
 %3 = load i32, i32* %2
 %4 = load i32, i32* @y
 %5 = icmp sgt i32 %3, %4
 br i1 %5, label %6, label %10
                                 ; preds = %0 → Function
6:
 %7 = load i32, i32* %2
 %8 = load i32, i32* @y
 %9 = sub nsw i32 %7, %8
 store i32 %9, i32* %2
 br label %10
10:
                                 ; preds = \%6, \%0
 %11 = load i32, i32* %1
 ret i32 %11
```

### LightIR 片段



```
@y = global i32 36
define i32 @main() #0 {
 %1 = alloca i32
 %2 = alloca i32
 store i32 0, i32* %1
 store i32 16, i32* %2
                                               → BasicBlock
 %3 = load i32, i32* %2
 %4 = load i32, i32* @y
 %5 = icmp sgt i32 %3, %4
 br i1 %5, label %6, label %10
                                 preds = \%0
6:
 %7 = load i32, i32* %2
 %8 = load i32, i32* @y
 %9 = sub nsw i32 %7, %8
                                               → Instruction
 store i32 %9, i32* %2
 br label %10
10:
                                 ; preds = \%6, \%0
 %11 = load i32, i32* %1
 ret i32 %11
```

### LightIR 类型系统



#### □简介

■LightIR 每条指令或操作数都具有自己的类型,其中分为基本类型与组合类型

### □基本类型 (LightIR类型系统中原生的类型)

■i1: 1位宽的整数类型

■i32: 32位宽的整数类型

■float: 单精度浮点数类型

■ label:标识符类型(基本块的类型)

### □组合类型(LightIR类型系统中,通过类型与运算符组合形成的类型)

■组合类型包括, 指针类型, 数组类型, 函数类型

### LightIR 组合类型



#### □指针类型

■格式: <type>\*

■例如: i32\*, [10 x i32]\*

#### □数组类型

■格式: [n x <type>]

■例如: [10 x i32], [10 x [10 x i32]]

#### □函数类型

■格式: <ret-type>@(<arg-type>...)

■详解:函数类型格式中有两个组成部分,返回值类型与参数类型列表,函数类型不会在 IR 中显示的表示出来。

### LightIR 的指令

- □LightIR 保留了LLVM IR SSA 形式、三地址指令、强类型系统的特点,但指令数量远小于 LLVM,按照种类可分为以下指令:
  - ■终止指令
  - ■二元运算指令
  - ■内存操作指令
  - ■类型转换指令
  - ■其他指令...
- □在介绍具体指令时,遵循以下符号约定
  - ■以<>符号括起来的代表指令格式中必选项,以[]括起来的代表指令格式中可重复项且至少存在一项。以%标记的代表IR中的虚拟寄存器

### LightIR 终止指令



#### □概念

■程序基本块只有一个入口与出口,顺序执行每一条语句,每个程序基本块的最后一条指令 称为终止指令

#### □ret 指令

■概念: 返回指令, 将控制流从函数返回给调用者

#### ■形式:

> ret <type> <value> 例: ret i32 %0

> ret void 例: ret void

#### □br 指令

■概念: 跳转指令, 使控制流转移到当前功能中的另一个基本块

#### ■形式:

> br i1 <cond>, label <iftrue>, label <iffalse> 例: br i1 %cond, label %truebb label %falsebb

> br label <dest> 例: br label %bb

### 二元运算指令



#### □概念

■包括add/sub/mul/sdiv/fadd/fsub/fmul/fdiv八种二元运算操作,返回计算后的结果

#### □形式

- <result> = <binary-op> <type> <op1>, <op2>
- ■注: <binary-op> 为八种二元运算操作之一,其中 add/sub/mul/sdiv 操作数是 i32 类型, fadd/fsub/fmul/fdiv 操作数是float类型

#### □例子

- %2 = sub i32 %1, %0
- %2 = fdiv float %1, %0

### 内存操作指令



#### □概念

■LightIR是SSA格式的,同一个虚拟寄存器只会被赋值一次,对于需要多次赋值的变量,在翻译时在栈上分配相应的空间,并通过内存操作指令对其读写

#### □alloca 指令

- ■概念: 在栈上根据变量类型分配相应大小的空间
- ■形式: <result> = alloca <type>
- ■例子:
  - > %ptr = alloca i32
  - > %ptr = alloca [10 x i32]

### 内存操作指令



#### □load 指令

■概念: 从栈上分配的地址空间中取数据到虚拟寄存器中

■形式: <result> = load <type>, <type>\* <pointer>

■例子: %val = load i32, i32\* %ptr

#### □store 指令

■概念:将虚拟寄存器中数据存到从栈上分配的地址空间中

■形式: store <type> <value>, <type>\* <pointer>

■例子: store i32 3, i32\* %ptr

### 类型转换指令



#### □概念

■将数据从某个类型转换到另一个类型的指令

#### □zext 指令

■概念:将操作数从 i1 类型零扩展到 i32 类型

■形式: <result> = zext i1 <value> to i32

■例子: %1 = zext i1 %0 to i32

### □fptosi指令

■概念: 将操作数从 float 类型转换为 i32 类型

■形式: <result> = fptosi float <value> to i32

■例子: %Y = fptosi float 1.0E-247 to i32

### 类型转换指令



### □sitofp 指令

■概念: 将操作数从 i32 类型转换为 float 类型

■形式: <result> = sitofp <type> <value> to <type2>

■例子: %1 = sitofp i32 257 to float

### 其他指令



#### □icmp和fcmp指令

- ■形式: <result> = icmp/fcmp <cond> <type> <op1>, <op2>
- ■概念:根据两个整数的比较返回布尔值,
  - ▶ icmp: <cond> = eq(等于) ne(不等于) sgt(大于) sge(大于等于) slt(小于) sle(小于等于)
  - ▶ fcmp: <cond> = eq(等于) ne(不等于) ugt(大于) uge(大于等于) ult(小于) ule(小于等于)

#### ■例子:

- > %2 = icmp sge i32 %0, %1
- > %0 = fcmp ult float 4.0, 5.0

#### □call 指令

- ■概念: call 指令是调用指令, 用于使控制流转移到指定的函数
- ■形式: <result> = call <return ty> <func name>(<function args>)
- ■例子:
  - > %2 = call i32 @gcd( i32 %1, i32\* %0)
  - call @output( i32 %1)

### 其他指令



### □getelementptr 指令

- ■概念: getelementptr指令用于获取数组结构的元素的地址。getelementptr仅执行地址计算,并且不访问内存
- ■形式: <result> = getelementptr <type1>, <type2>\* <ptrval> [, <type> <idx>]
  - ▶注: <type1>是初始计算偏移的元素类型(若为数组类型,则在通过偏移值计算索引地址时进行降维,得到新的计算偏移的元素类型),<type2>表示索引开始的指针类型,<ptrval>是计算偏移的起始地址的指针,[]表示可重复参数,里面表示的数组索引的偏移值的类型与偏移值。

#### ■例子:

- > %2 = getelementptr [10 x i32], [10 x i32]\* %1, i32 0, i32 %0
- > %2 = getelementptr i32, i32\* %1, i32 %0

### 2024年秋季学期《编译原理和技术》



# 一起努力 打造国产基础软硬件体系!

李诚

国家高性能计算中心(合肥)、信息与计算机国家级实验教学示范中心 计算机科学与技术学院 2024年9月30日